



Universidad Europea

**Máster de Formación Permanente en Inteligencia
Artificial Aplicada al Deporte**

IntApp — Guía de Desarrollo del TFM

*Aplicación individualizada para la prevención de lesiones de miembro inferior
en deportistas mediante Machine Learning*

Alumno: Roberto Franco

Director: Javier Sánchez

Fecha: Abril 2026

1. Introducción al proyecto

IntApp es una aplicación de evaluación del riesgo de lesión deportiva pensada para fisioterapeutas. Introduces los resultados de las pruebas físicas de un deportista (fuerza muscular, movilidad articular, equilibrio y control) y la aplicación calcula automáticamente si ese deportista tiene un riesgo bajo, medio o alto de lesionarse.

Internamente usa machine learning: un algoritmo entrenado con datos de 500 deportistas sintéticos que aprende a reconocer qué combinaciones de valores se asocian a mayor riesgo. Además, para cada predicción, la aplicación explica qué variables han sido las más determinantes (explicabilidad SHAP).

Arquitectura del sistema

Datos de entrada (23 variables) → Preprocesamiento (ratios, asimetrías, normalización) → Modelo ML (Random Forest / Logistic Regression / Gradient Boosting) → Predicción de riesgo (bajo/medio/alto) + Explicación SHAP

Lo que recibes ya hecho

- 6 módulos Python en src/ (variables, generador de datos, preprocesador, modelo, evaluador)
- 6 notebooks Jupyter ejecutables en orden
- App Streamlit con interfaz visual de semáforo
- Documentación completa

2. Estructura del proyecto

```
IntApp/
├── README.md
├── INSTRUCCIONES_ROBERTO.md
├── requirements.txt
├── docs/
│   ├── Protocolo_Scoring_Roberto_Franco.docx    ← TU PRIMER PASO
│   └── Guia_TFM_Roberto_Franco.docx
├── datos/
│   ├── raw/                                     ← Datos reales futuros
│   ├── sinteticos/                             ← CSV generado por notebook 01
│   └── procesados/                             ← CSV transformado
├── modelos/                                    ← Modelos entrenados (.joblib)
├── figuras/                                    ← Gráficos para el TFM
├── notebooks/
│   ├── 01_generacion_datos.ipynb
│   ├── 02_exploracion_datos.ipynb
│   ├── 03_entrenamiento_modelo.ipynb
│   ├── 04_interpretacion_modelo.ipynb
│   ├── 05_analisis_sensibilidad.ipynb
│   └── 06_validacion_sinteticos.ipynb
├── src/
│   ├── variables.py
│   ├── generador_datos.py
│   ├── preprocesador.py
│   ├── modelo.py
│   └── evaluador_riesgo.py
└── app/
    └── streamlit_app.py
```

Flujo de ejecución: Notebook 01 → 02 → 03 → 04 → 05 → 06 → App Streamlit

3. Tu trabajo: los 6 huecos que debes completar

Hueco 1: Protocolo de scoring clínico — Prioridad máxima

Archivo: `docs/protocolo_scoring.md`

Un documento donde defines, ANTES de tocar código, cuál es tu razonamiento clínico. Incluye qué variables usas, qué umbrales de riesgo eliges y por qué, y qué reglas determinan que un deportista es de alto, medio o bajo riesgo. Va primero porque el modelo aprende a partir de las etiquetas que tú defines.

Capítulo del TFM: *Metodología*

Hueco 2: Rangos y referencias de las variables

Archivo: `src/variables.py`

El diccionario central del proyecto con las 23 variables clínicas. Los rangos actuales son aproximados. Busca las líneas «# TODO ROBERTO: ajustar» y actualiza cada rango con los valores de la literatura. Ejemplo: si la dorsiflexión en tu población es 38°-52°, cambia (35, 50) por (38, 52).

Capítulo del TFM: *Marco Teórico + Metodología*

Hueco 3: Reglas de clasificación del riesgo

Archivo: `src/generador_datos.py` → función `generar_label()`

La función que decide qué etiqueta (bajo/medio/alto) recibe cada deportista. Es el corazón clínico del proyecto. Traduce las reglas de tu protocolo de scoring al formato del código. Hay ejemplos comentados que puedes adaptar.

Capítulo del TFM: *Metodología (aportación original)*

Hueco 4: Comparación y selección de modelos

Archivo: `notebooks/03_entrenamiento_modelo.ipynb`

El notebook entrena 3 modelos y muestra sus métricas. Ejecuta el notebook, analiza las métricas (accuracy, F1, matriz de confusión) y escribe en tu TFM por qué eliges un modelo sobre los otros.

Capítulo del TFM: *Resultados*

Hueco 5: Análisis de sensibilidad**Archivo:** [notebooks/05_analisis_sensibilidad.ipynb](#)

Permite variar los umbrales de tu scoring y ver cómo cambian las predicciones. Documenta qué pasa cuando cambias los umbrales y discute la robustez de tu sistema.

Capítulo del TFM: *Discusión***Hueco 6: Interpretación clínica de SHAP****Archivo:** [notebooks/04_interpretacion_modelo.ipynb](#)

Los gráficos SHAP se generan automáticamente. Tú debes interpretar QUÉ significan clínicamente: qué variables son las más importantes y si eso coincide con la literatura.

Capítulo del TFM: *Discusión de resultados*

4. Cómo ejecutar el proyecto

Paso 1: Abre Anaconda Prompt

Búscalo en el menú inicio de Windows.

Paso 2: Navega a la carpeta del proyecto

```
cd "<tu ruta>\IntApp"
```

Paso 3: Instala dependencias (solo la primera vez)

```
pip install -r requirements.txt
```

Paso 4: Abre JupyterLab

```
jupyter lab
```

Paso 5: Ejecuta los notebooks en orden

Orden	Archivo	Qué hace
1	01_generacion_datos.ipynb	Genera los 500 deportistas sintéticos
2	02_exploracion_datos.ipynb	Explora y visualiza el dataset
3	03_entrenamiento_modelo.ipynb	Entrena los tres modelos de clasificación
4	04_interpretacion_modelo.ipynb	Analiza qué variables son más importantes
5	05_analisis_sensibilidad.ipynb	Comprueba la robustez del modelo
6	06_validacion_sinteticos.ipynb	Valida los datos sintéticos

Ejecuta con «Run All» o celda a celda con Shift+Enter.

Paso 6: Lanza la aplicación

```
streamlit run app/streamlit_app.py
```

5. Correspondencia TFM ↔ código

Capítulo del TFM	Archivos del proyecto	Qué haces
Marco Teórico	variables.py	Justificas los rangos con citas
Metodología	protocolo_scoring.md, generador_datos.py	Defines el scoring, validas datos
Resultados	Notebooks 03, 04, 05, 06	Ejecutas y documentas
Discusión	Notebook 04 (SHAP)	Interpretas clínicamente
Aplicación clínica	app/streamlit_app.py	Demuestras el sistema
Limitaciones	—	Declaras circularidad epistémica

6. Encuadre académico

Autoría

La infraestructura técnica (pipeline de datos, entrenamiento de modelos, aplicación web) fue desarrollada como herramienta de soporte por el director del TFM. La aportación original del alumno consiste en:

- El diseño del sistema de scoring clínico
- La validación de rangos contra literatura
- La comparación y selección de modelos
- El análisis de sensibilidad
- La interpretación clínica de resultados

Sobre los datos sintéticos

Este proyecto usa datos generados por ordenador. Los datos sintéticos permiten desarrollar y validar el sistema, pero no sustituyen la validación con datos reales. El siguiente paso natural sería recoger datos reales y reentrenar el modelo.

Sobre la circularidad epistémica

El modelo aprende a partir de las etiquetas que tú mismo defines. Cuando el modelo predice con alta precisión, eso no demuestra que tus reglas sean clínicamente correctas; solo demuestra que el algoritmo aprende el patrón que le enseñaste. La evidencia independiente vendría de un estudio prospectivo con datos reales. Esto queda como línea de trabajo futuro.

El valor académico del TFM está en:

1. La revisión bibliográfica que sustenta la elección de variables
2. El diseño del protocolo de evaluación clínica
3. La demostración técnica de viabilidad
4. La identificación honesta de limitaciones

7. Preguntas frecuentes

¿Qué pasa si ejecuto los notebooks en orden equivocado?

Verás un error de archivo no encontrado. Reinicia desde el 01.

¿Puedo cambiar el número de deportistas?

Sí, cambia N_DEPORTISTAS en el notebook 01 y re-ejecuta todo desde ahí.

¿Qué modelo usa la app?

El que mejor F1 obtuvo en el notebook 03, guardado automáticamente.

¿Se guardan los datos de pacientes?

No, la app no persiste ningún dato.

¿Puedo usarla con datos reales?

Como prueba de concepto sí, pero no como herramienta de diagnóstico hasta validar con estudio prospectivo.

¿Dónde están las figuras para el TFM?

En la carpeta figuras/, generadas automáticamente por los notebooks.